TABELA DE DISPERSIE

- continuare –

C. Rezolvare coliziuni prin adresare deschisă - OPEN ADDRESSING

- > Toate elementele sunt memorate în interiorul tabelei, nu există liste memorate în afara tabelei.
- > Se mai numește și dispersie închisă (closed hashing).
 - > rezolvarea coliziunilor prin liste întrepătrunse (closed hashing) este o combinație între open adressing și separate chaining (open hashing)
- Fiecare intrare în tabelă conține fie un element al containerului, fie un marcaj pentru locație liberă (ex. NIL).
- > Nu se folosesc pointeri pentru înlănțuiri.
- Factorul de încărcare este subunitar $\alpha < 1$, altfel tabela este plină
- \triangleright Dezavantaj: tabela se poate umple ($\alpha = 1$). Soluție: se crește m, ceea ce presupune redispersarea elementelor.
- Avantaj: spațiul de memorie suplimentar (nu se memorează pointeri) oferă tabelei un număr mai mare de locații pentru același spațiu de memorie, putând rezulta coliziuni mai puține și acces rapid.
- > Secvența de locații care se examinează nu se determină folosind *pointeri*, ci se *calculează*
- La adăugare în tabelă, se examinează succesiv locațiile, până se găsește o locație liberă în care să se adauge cheia (elementul). În loc să fie fixată ordinea de verificare a tabelei (ex: 0,1,2...,m-1, ca la vectori) care ar necesita timp $\theta(m)$, secvența de poziții examinate depinde de cheia (elementul) care se inserează.
- Se extinde funcția de dispersie $d: U \times \{0, ..., m-1\} \rightarrow \{0, ..., m-1\}$
 - o al doilea argument al funcției se numește număr de verificare
- Pentru o cheie $c \in U$ secvența $< d(c,0), d(c,1), \dots, d(c,m-1) >$ se numește secvența de verificare a cheii c

<u>Cerință</u>

- secvența de verificare a oricărei chei $c \in U < d(c,0), d(c,1), ..., d(c,m-1) >$ trebuie să fie o permutare a mulțimii < 0,1,...,m-1 >
 - o pentru ca la adăugarea oricărei chei să fie verificate toate locațiile din tabelă

Ipoteza dispersiei uniforme simple (SUH)

○ Pentru orice cheie $c \in U$, permutarea < d(c,0), d(c,1), ..., d(c,m-1) > poate să apară sub forma oricărei permutări a < 0,1,...,m-1 >

Sunt 3 metode pentru a stabili secvența de verificare a unei chei c, a.î. să se asigure faptul că $c \in U$ < d(c,0), d(c,1), ..., d(c,m-1) > este o permutare a mulțimii < 0,1,...,m-1 >. Acestea vor fi descries, în continuare.

C.1. Verificare liniară – LINEAR PROBING

$$d(c,i) = (d'(c)+i) \mod m \qquad \forall i = 0,1,...,m-1$$

- $d': U \to \{0, ..., m-1\}$ este o funcție de dispersie uzuală (ex: $d'(c) = c \mod m$)
- Fiind dată o cheie c, secvența ei de verificare este < d'(c), d'(c) + 1, d'(c) + 2, ..., m 1, 0, 1, ... d'(c) 1 >
- ➤ Problema: **grupare primară** se formează șiruri lungi de locații ocupate, crescând timpul mediu de căutare

C.2. Verificare pătratică – QUADRATIC PROBING

$$d(c,i) = (d'(c) + c_1 \cdot i + c_2 \cdot i^2) \mod m$$
 $\forall i = 0,1,...,m-1$

 $d': U \to \{0, ..., m-1\}$ este o funcție de dispersie uzuală (ex: $d'(c) = c \mod m$), $c_1 \neq 0$ și $c_2 \neq 0$ sunt constante auxiliare fixate la inițializarea funcției de dispersie.

- \triangleright Constantele $c_1 \neq 0$ și $c_2 \neq 0$ se pot determina euristic
 - O Pentru a asigura faptul că secvența de verificare este o permutare $\{0, ..., m-1\}$
 - m se alege putere a lui 2 și $c_1 = c_2 = 0.5$
 - m se alege număr prim de forma $\mathbf{4} \cdot \mathbf{k} + \mathbf{3}$, $\mathbf{d}'(\mathbf{c}) = \mathbf{c} \mod \mathbf{m}$ și $\mathbf{c_1} = \mathbf{0}$, $\mathbf{c_2} = (-1)^i$
- Fiind dată o cheie c, prima poziție examinată este d'(c), după care următoarele poziții examinate sunt decalate cu cantități ce depind într-o manieră pătratică de locația anterior examinată.
- Problema: grupare secundară dacă 2 chei au aceeași poziție de start a verificării, atunci secvența lor de verificare coincide (dacă $d(c',0) = d(c'',0) \Rightarrow d(c',i) = d(c'',i) \quad \forall i = 0,1,...,m-1$)
- Experimental: funcționează mai bine decât verificarea liniară

C.3. Dispersia dublă – DOUBLE HASHING

$$d(c,i) = (d_1(c) + i \cdot d_2(c)) \mod m$$
 $\forall i = 0,1,...,m-1$

 d_1 și d_2 sunt funcții de dispersie aleatoare.

- Este considerată una dintre cele mai bune metode disponibile pentru adresarea deschisă
- Fiind dată o cheie c, prima poziție examinată este $d_1(c)$, după care următoarele poziții examinate sunt decalate față de poziția anterioară cu $d_2(c)$ mod m.
- $\succ d_2(c)$ și m să fie prime între ele pentru a fi parcursă întreaga tabelă
- > Exemplu
 - \circ *m* prim
 - $d_1(c) = c \mod m$ $d_2(c) = (1 + c \mod m')$
 - o m' se alege de obicei m-1 sau m-2
- Performanța dispersiei duble apare ca fiind foarte apropiată de performanța schemei ideale a dispersiei uniforme ($\theta(m^2)$) secvențe de verificare posibile pentru o cheie)
 - o în cazurile C1.1 și C1.2, numărul secventelor de verificare posibile penru o cheie e doar $\theta(m)$

Presupuneri și notații:

- > Pp. că în container memorăm doar chei
- > O locație din tabelă va conține:
 - o NIL (constantă simbolică) dacă locația e liberă (nu conține o cheie)
 - O cheie din container

Reprezentarea containerului folosind o TD cu adresare deschisă

Container

m: Intreg {nr.de locații din tabelă}

ch: TCheie[0..m-1] {cheile din container}

d: TFunctie {funcția de dispersie asociată}

ADĂUGARE

Dacă adăugăm o cheie c, determinăm locația la care ar trebui memorată în tabelă (i=d(c)), după care vom avea două situații

- Locația i este liberă (NIL, în convenția noastră) \Rightarrow caz favorabil, memorăm cheia
- Locația i nu este liberă \Rightarrow avem coliziune
 - o verificăm, pe rând, locațiile din tabelă, în ordinea dată de secvența de verificare $< d(c,0), d(c,1), \ldots, d(c,m-1) >$
 - o dacă găsim o locație liberă, adăugăm
 - o dacă toate locațiile din secvența de verificare sunt ocupate ⇒ tabela este plină

EXEMPLE

1. Adresare deschisă cu verificare liniară

- *m*=10
- $d(c,i) = (d'(c)+i) \mod m$ $\forall i = 0,1,...,m-1$
- $d'(c)=c \mod m$

c	5	15	13	22	20	35	30	32	2
d' (c)	5	5	3	2	0	5	0	2	2

Pas 1. Inițializare

Indice	0	1	2	3	4	5	6	7	8	9
Cheie	NIL									

Pas 2. Adăugăm cheia 5

Indice	0	1	2	3	4	5	6	7	8	9
Cheie	NIL	NIL	NIL	NIL	NIL	5	NIL	NIL	NIL	NIL

Pas 3. Adăugăm cheia 15

- Secvența de verificare a cheii este <5, 6, 7, 8, 9, 0, 1, 2, 3, 4>
- Prima locație liberă din secvență este locația 6, acolo se va adăuga

Indice	0	1	2	3	4	5	6	7	8	9
Cheie	NIL	NIL	NIL	NIL	NIL	5	15	NIL	NIL	NIL

....

La final, tabela va fi

Indice	0	1	2	3	4	5	6	7	8	9
Cheie	20	30	22	13	22	5	15	35	2	NIL

2. Adresare deschisă cu verificare pătratică

- *m*=8
- $d(c,i) = (d'(c) + c_1 \cdot i + c_2 \cdot i^2) \mod m$ $\forall i = 0,1,...,m-1$
- $d'(c)=c \mod m$
- $c_1 = c_2 = 0.5$

c	5	15	13	2	0	32
d'(c)	5	7	5	2	0	0

Pas 1. Inițializare

Indice	0	1	2	3	4	5	6	7
Cheie	NIL							

Pas 2, 3. Adăugăm cheile 5, 15

Indice	0	1	2	3	4	5	6	7
Cheie	NIL	NIL	NIL	NIL	NIL	5	13	15

Pas 4 Adăugăm cheia 13

- Secvența de verificare a cheii este <5, 6, ...>
- Prima locație liberă din secvență este locația 6, acolo se va adăuga

....

La final, tabela va fi

Indice	0	1	2	3	4	5	6	7
Cheie	0	32	2	NIL	NIL	5	13	15

3. Adresare deschisă cu dispersie dublă

• *m*=13

•
$$d(c,i) = (d_1(c) + i \cdot d_2(c)) \mod m$$
 $\forall i = 0,1,...,m-1$

• $d_1(c)=c \mod m, d_2(c)=1+c \mod (m-2)$

С	79	69	96	14
d ₁ (c)	1	4	5	1
d ₂ (c)	3	4	9	4

Adaugăm cheile 79, 69, 96 și tabela devine

Indice	0	1	2	3	4	5	6	7	8	9	10	11	12
Cheie	NIL	79	NIL	NIL	69	96	NIL						

Pentru cheia 14, care e în coliziune, secvența de verificare e 1, 5, 9,

• prima poziție liberă e 9, adăugăm

Tabela finală e

Indice	0	1	2	3	4	5	6	7	8	9	10	11	12
Cheie	NIL	79	NIL	NIL	69	96	NIL	NIL	NIL	14	NIL	NIL	NIL

```
Subalgoritmul ADAUGĂ (c, ch) este
```

```
{c:Container, ch:TCheie}
        i \leftarrow 0 {numărul de verificare}
        gasit←fals {nu am găsit poziția de adăugare}
        repetă
                j \leftarrow c.d(ch,i) {locația de verificat}
(*)
                dacă c.\text{ch}[j]=NIL atunci
                         c.\text{ch}[j] \leftarrow ch \text{ \{memorez cheia\}}
                         gasit←adev {am găsit poziția unde putem adăuga}
                  altfel
                         i \leftarrow i+1 {căutăm mai departe pe secvența de verificare}
                sfdacă
        până când (i=c.m) sau (gasit)
        dacă i=c.m atunci {tabela e plină}
                @ depășire tabelă
        Sfdacă
    sfADAUGĂ
```

CĂUTARE

- pp. că vrem să căutăm cheia c

- o căutăm în ordinea dată de secvența de verificare a cheii < d(c,0), d(c,1), ..., d(c,m-1) >până dăm de o locație liberă (marcată cu NIL)
- dacă găsim cheia undeva pe secvența de verificare ⇒ căutare cu succes, altfel căutare fără succes
- în exemplul 1
 - o căutăm **35 (cu succes)**: căutăm în ordinea 5, 6, 7
 - o găsim pe poziția 7
 - o căutăm 45 (fără succes): căutăm în ordinea 5, 6, 7, 8, NIL
 - nu găsim cheia pe secvența de verificare

```
Funcția CAUTĂ (c, ch) este
{c:Container, ch:TCheie}

i←0 {numărul de verificare}

gasit←fals {nu am găsit cheia}

repetă

j←c.d(ch,i) {locația de verificat}

dacă c.ch[j]=ch atunci {am găsit cheia}

gasit←adev

altfel

i←i+1 {căutăm mai departe pe secvența de verificare}

sfdacă

până_când (c.ch[j]=NIL) sau (i=c.m) sau (gasit)

CAUTĂ← gasit

sfCAUTĂ
```

STERGERE

Ștergerea unei chei c

- identificăm locația i la care este memorată cheia (ca și la căutare)
- nu putem marca locația *i* cu NIL (ca și cum ar fi liberă), deoarece ar fi imposibil să mai accesăm orice cheie a cărei inserare a verificat locația *i* și a găsit-o liberă

Sunt două soluții la ștergere

- 1. O solutie este de a marca la locatia i o valoare speciala, STERS (în loc de NIL)
 - vom modifica ADAUGĂ astfel încât să trateze locațiile marcate cu ŞTERS ca și cum ar fi libere
 linia marcată cu (*) în ADAUGĂ o vom înlocui cu
 - dacă (c.ch[i]=NIL) sau (c.ch[i]=STERS) atunci
 - nu este necesar să modificăm CAUTĂ
- 2. Prin deplasări ale datelor, astfel încât să nu mai existe riscul de a nu regăsi o cheie

Ștergere prin deplasări de date

Ilustrăm ideea ștergerii prin deplasări de date, presupunând verificarea liniară a tabelei.

- o vrem să ștergem cheia c
- o o localizăm (căutând pe secvența de verificare)
- o fie i locația pe care se află cheia c și care trebuie ștearsă

Va trebui să ne asigurăm că ștergerea locației i (marcarea acesteia cu NIL) nu afectează regăsirea cheilor care au fost memrate pornind de la locația i (la adăugare, au găsit locația ocupată).

Pas 1. Luăm, pe rând, locațiile în ordinea secvenței de verificare $j = i+1, i+2, \dots m-1, 0, \dots$ până la o zonă liberă

- o Fie p locația unde trebuia memorată data (cheia, în cazul nostru), de la locația j
 - \circ p = d(ch[j])
 - o dacă am șterge cheia de la locația *i*, am putea regăsi cheia de la locația *j*, pornind de la *p* (iterând pe secvența de verificare, fără a da de o locație liberă)?
- o Avem de tratat două cazuri, fiecare caz cu 3 subcazuri

```
1. i < j

1a) 0 \le p \le i

0 ..... p ..... i ..... j ..... m-1
```

 \triangleright (*) se mută data (cheia, în cazul nostru) de la locația j la locația i și se continua cu ștergerea locației j

$$\begin{array}{ll}
\circ & ch[i] \leftarrow ch[j] \\
\circ & i \leftarrow j
\end{array}$$

> Salt la **Pas 1**.

1b)
$$i
0 j $m-1$$$

- > nu e necesară mutare de date (ștergerea lui i nu afectează)
- > Salt la **Pas 1**.

1c)
$$j 0 j p $m-1$$$

- > se efectuează mutarea de date (*) de la 1a)
- > Salt la **Pas 1**.

2a)
$$0 \le p \le j$$

0 p j $m-1$

- > nu e necesară mutare de date (ștergerea lui i nu afectează)
- > Salt la Pas 1.

2b)
$$j 0 j p i $m-1$$$

> se efectuează mutarea de date (*) de la 1a)

> Salt la **Pas 1**.

2c)
$$i 0 j i p $m-1$$$

> nu e necesară mutare de date (ștergerea lui *i* nu afectează)

> Salt la **Pas 1**.

Pas 2. La încheierea structurii repetitive de la Pas 1, se poate șterge cheia de locația de la i.

Exemplu Considerăm exemplul 1 - adresare deschisă cu verificare liniară

• *m*=10

• $d(c,i) = (d'(c)+i) \mod m$ $\forall i = 0,1,...,m-1$

• $d'(c)=c \mod m$

c	5	15	13	22	20	35	30	32	2
d' (c)	5	5	3	2	0	5	0	2	2

Vrem să ștergem cheia 5.

Tabela inițială este

Indice	0	1	2	3	4	5	6	7	8	9
Cheie	20	30	22	13	22	5	15	35	2	NIL

i	j	Locația j liberă?	p	Caz
5	6	NU	5	1a) ⇒ mutare date
6	7	NU	5	1a) ⇒ mutare date
7	8	NU	2	1a) ⇒ mutare date
8	9	DA ⇒ STOP	-	Pas 2, se șterge cheia de la <i>i</i>

Tabela finală va fi

Indice	0	1	2	3	4	5	6	7	8	9
Cheie	20	30	22	13	22	15	35	2	NIL	NIL

Iteratorul pe un container reprezentat folosind o TD cu adresare deschisă este simplu de implementat

- o se iterează vectorul asociat, iterând doar pe pozițiile pe care e memorată o cheie diferită de NIL (în convenția noastră).
- $\circ \theta(m)$

În directorul asociat cursului, găsiți implementarea parțială a containerului Colecție reprezentat folosind o TD cu adresare deschisă și verificare liniară.

Analiza dispersiei cu adresare deschisă

1. <u>Teorema.</u> Într-o TD cu adresare deschisă, în *ipoteza dispersiei uniforme simple* (SUH), cu factor de încărcare $\alpha = \frac{n}{m} < 1$ numărul *mediu* de verificări este CEL MULT

CORMEN, THOMAS H. - LEISERSON, CHARLES - RIVEST, RONALD R.: Introducere în algoritmi. Cluj-Napoca: Editura Computer Libris Agora, 2000.

- $\Rightarrow \frac{1}{1-\alpha}$ pentru adăugare și căutare fără succes
- $\Rightarrow \frac{1}{\alpha} \cdot ln \frac{1}{1-\alpha}$ pentru căutare cu succes

Demonstrațiile sunt schițate și la http://www.cs.ubbcluj.ro/~gabis/sda/Cursuri/Curs9-10%20-%20Tabele%20deschisa,%20Alte%20variant e)/Demonstratii%20Complexitati%20-%20TD%20Adresare%20Deschisa/AdresareDeschisa.pdf

CONCLUZII

- Dacă α e constant $\Rightarrow \theta(1)$ în **medie** pentru operații
- Caz defavorabil O(n)

Observație

- în cazul în care se folosește vector dinamic pentru implementarea tabelei, analiza anterioară a complexităților este valabilă pentru cazul **amortizat**
- deși, din perspectivă teoretică, adresarea deschisă e mai performantă decât cea închisă, în bibliotecile existente (Java, STL), TD sunt implementate prin liste independente
 - Java *HashTable*
 - se poate preciza, prin constructor, capacitatea inițială a tabelei și factorul de încărcare
 - implicit m=11, factorul de încărcare maxim e $\alpha=0.75$
 - redispersare dacă se depăseste factorul de încărcare implicit
 - STL unordered_map/set
 - implicit m=8, factorul de încărcare maxim e $\alpha=1$
 - redispersare dacă se depășeste factorul de încărcare implicit

PROBLEME

- 1. Considerând o tabelă de dispersie cu adresare deschisă, scrieți un algoritm pentru operația de **ștergere** și modificați operația **adaugă** și **caută** pentru a încorpora valoarea specială **ȘTERS.**
- 2. Se consideră o tabelă de dispersie cu adresare deschisă, cu dispersie uniformă și factor de încărcare 0.5. Dați margini superioare pentru numărul mediu de verificări într-o căutare cu succes și o căutare fără succes.

2. DISPERSIA PERFECTĂ (PERFECT HASHING)

- Scop să nu existe coliziuni.
 - o Cât de mare să fie tabela încât să fim siguri că nu sunt coliziuni?
 - O Dacă $m=N^2$, atunci tabela este fără coliziuni cu probabilitatea cel puțin 0.5.
 - \blacksquare N numărul de chei din container
 - o Impractic.
- Soluție Dispersia perfectă (perfect hashing)
 - o Doar dacă avem o colecție STATICĂ de chei (nu se adaugă chei)
 - o Se folosește o TD de dimensiune N (tabela **primară**)
 - o În locul listelor independente se folosește o altă TD (tabela secundară)
 - O Tabela secundară de la o locație i se va construi cu dimensiunea n_i^2 unde n_i este numărul de elemente din acea tabelă (numărul de coliziuni de la locația i).
 - Tabela secundară se va construi cu o altă funcție de dispersie şi va fi reconstruită până nu va avea coliziuni.
 - Se poate demonstra că spațiul total de memorare pentru tabelele secundare este cel mult $2*N \Rightarrow O(N)$.
- Fie p numărul prim mai mare decât cea mai mare cheie.
- Funcțiile de dispersie se aleg dintr-o familie de funcții de dispersie universală.
 - $o d_{a,b}(x) = ((a \cdot x + b) \mod p) \mod m$
 - o $1 \le a \le p-1$, $0 \le b \le p-1$ (a şi b selectate aleator la inițializarea funcției de dispersie)
 - \circ m = N
- Performanța în caz **defavorabil** este $\theta(1)$ (se caută cel mult 2 poziții cea din TD principală și secundară)

EXEMPLU

- o 15 litere: I, N, S, X, E,....
- \circ N=m=15
- o Fiecărei litere îi asociem ca hashCode numărul de ordine al literei în alfabet
- o Dacă a=3 și b=2 (alese aleator)
- \circ p=29

Litera	I	N	S	X	Е
hashCode	9	14	19	24	5
d(hashCode)	0	0	1	1	2

Coliziuni

- poziția 0 I, N
- poziția 1 S, X
- poziția 2 E
- ...

- O Pentru pozițiile unde nu avem coliziuni (ex. poziția 2) avem o TD secundară cu un singur element și d(x)=0
- o Pentru pozițiile cu **2** elemente, vom avea o TD secundară cu 4 elemente și diferite funcții de dispersie, alese din același *univers*, cu diferite valori aleatoare pentru *a* și *b*.
- o De ex,. pentru poziția 0, putem defini a=4 și b=11 și vom avea
 - d(I)=d(9)=2, d(N)=d(14)=1
- o Pentru poziția 1, să pp. că avem a=5 și b=2.
 - d(S)=d(19)=2, d(X)=d(24)=2 => coliziune
 - Alegem alte valori pentru a și b de ex. a=2 și b=13. Vom avea
 - d(S)=d(9)=2, d(X)=d(14)=3

3. ALTE VARIANTE DE DISPERSIE

1. Dispersia Cuckoo (Cuckoo hashing)

- o Se folosesc 2 TD cu două funcții de dispersie diferite
 - Fiecare tabelă e mai mult de jumătate goală
- O Se poate garanta că un element va fi fie în prima, fie în a doua tabelă.
- o **Căutarea** și **ștergerea** sunt simple (elementul se va localiza în una din cele 2 TD)
- Inserarea unei chei c
 - Se încearcă adăugarea în prima tabelă. Dacă e liber, se adaugă.
 - Dacă poziția în prima tabelă e ocupată de cheia c', se scoate c' din prima tabelă, se adaugă noul element c. Elementul scos din prima tabelă c' se va adăuga în a doua. Dacă poziția în a doua tabelă e ocupată de c'', se va scoate acel element (în locul său se va adăuga elementul c' din prima tabelă) și c'' se va adăuga în prima tabelă. Se va repeta procesul până se va obține o poziție liberă. Dacă se revine în aceeași poziție de start (există un ciclu) se face re-dispersare (**rehashing**)

2. Liste independente interconectate (Linked hashing)

- JAVA *LinkedHashMap*
 - o HashMap din Java folosește rezolvare coliziuni prin liste independente (inițial m=16)
 - o Dacă α >0.75, se face redispersare (*rehashing*) *m* se dublează
 - Java 8 în locul listelor înlănțuite se folosesc arbori binari de căutare echilibrați $\Rightarrow \theta(\log_2 n)$ caz defavorabil pentru căutare
- Combină ideea de TD și listă înlănțuită.
 - O Păstrează o listă dublu înlănțuită cu toate elementele din TD într-o anumită ordine (implicit -în ordinea în care au fost adăugate în dicționar)
 - Fiecare intrare în tabelă (*Entry*) nod care memorează perechea <c,v> are 2 pointeri adiționali spre perechea *anterioară* și cea *următoare* (adresele sunt ale nodurilor din lista dublu înlănțuită)
- Datorită mecanismului de memorare, cheile vor fi returnate (la iterare) în ordinea în care au fost adăugate (varianta implicită *insertion order* se poate modifica la *access order*: de la cea mai recent accesată la cea mai devreme accesată).

- Aceeași perfomanță ca și *HashMap*
- Ca și implementarea *HashMap*, *LinkedHashMap* nu e sincronizată (nu funcționează cu acces concurent)
- **Dezavantaj** spațiu de memorare suplimentar pentru lista înlănțuită
- Avantaj iterare în $\theta(n)$ (față de $\theta(n+m)$)